

AIRFLOW Group project

Sujet de projet : Plateforme distribuée de scraping, orchestration et supervision des entreprises belges

Contexte

concevoir une plateforme complète de collecte, d'orchestration, de traitement et de visualisation des données publiques des entreprises belges.

Les données proviennent principalement de :

- la Banque-Carrefour des Entreprises (BCE/KBO)
- du Moniteur belge
- de la Banque Nationale de Belgique (BNB)
- des publications légales liées aux entreprises

Exemples de sources :

- <https://kbopub.economie.fgov.be/kbopub/toonondernemingps.html?lang=fr&ondernemingsnummer=203430576#null>
 - <https://consult.cbso.nbb.be/>
-

Objectifs

Le projet doit permettre de :

- orchestrer automatiquement des pipelines de scraping et de traitement ;
- gérer les dépendances entre les différentes étapes du pipeline ;
- stocker les documents bruts sur HDFS ;
- extraire et structurer les informations importantes ;

- maintenir un historique des scrapes et des changements ;
 - superviser l'état global de la plateforme ;
 - produire des indicateurs analytiques sur les entreprises collectées ;
 - gérer dynamiquement la découverte de nouvelles entreprises ;
 - détecter et traiter les entreprises fermées ou inactives ;
 - fournir une interface d'administration et de monitoring temps réel.
-



Architecture fonctionnelle

Le projet doit être organisé en plusieurs domaines fonctionnels clairement séparés.

1. Acquisition des données

Le système doit être capable de lire un ou plusieurs fichiers CSV contenant des numéros d'entreprises belges.

À partir de ces numéros :

- le système tente d'accéder aux pages HTML publiques ;
- les pages récupérées sont enregistrées brutes sur HDFS ;
- aucune extraction métier ne doit être effectuée au moment du scraping.

Le rôle du scraper est uniquement :

- télécharger ;
- valider ;
- stocker les documents bruts.

Les pages d'erreur ne doivent jamais être enregistrées.

Documents concernés

Le système doit récupérer :

- les pages principales des entreprises ;
- les publications du Moniteur belge ;

- les documents de la Centrale des Bilans (BNB) ;
- les statuts ;
- les pouvoirs de représentation ;
- les autres documents liés aux entités.

Chaque source doit être considérée comme une acquisition indépendante.

Métadonnées obligatoires

Chaque document récupéré doit être accompagné de métadonnées :

- date et heure du scraping ;
 - source ;
 - statut du téléchargement ;
 - code HTTP ;
 - proxy/IP utilisé ;
 - nombre de tentatives ;
 - dernière date de mise à jour.
-

2. Extraction et structuration des données

Une fois les HTML présents sur HDFS, des traitements doivent être déclenchés automatiquement afin d'extraire les informations structurées.

Les traitements doivent notamment permettre d'extraire :

- les informations générales de l'entreprise ;
- les dirigeants et représentants ;
- les capacités entrepreneuriales ;
- les qualités ;
- les autorisations ;
- les activités TVA ;
- les données financières ;
- les liens entre entités ;

- les établissements ;
- les publications et documents associés.

Les données structurées doivent être enregistrées dans une base de données adaptée.

Découverte dynamique de nouvelles entreprises

Le système doit être capable de découvrir automatiquement de nouvelles entreprises lors de l'analyse des liens entre entités.

Ces entreprises découvertes :

- doivent être ajoutées automatiquement à la file de traitement ;
- doivent être historisées ;
- doivent être distinguées des entreprises initialement présentes dans les CSV.

Le système doit conserver la relation entre :

- l'entreprise source ;
 - l'entreprise découverte ;
 - la raison de la découverte.
-

3. Gestion du cycle de vie des entreprises

Le système doit maintenir les données à jour dans le temps.

Certaines entreprises peuvent :

- devenir inactives ;
- être radiées ;
- être fusionnées ;
- changer de statut juridique.

Le pipeline doit donc prévoir :

- des vérifications régulières de statut ;
- des mécanismes de rescraping ;

- la mise à jour des informations existantes.
-

Politique de fraîcheur des données

Une entreprise ne peut pas rester sans mise à jour pendant une longue période.

Le système doit garantir qu'une entreprise soit rescrapée régulièrement.

Exemple :

- une entreprise doit être revalidée au minimum toutes les deux semaines.
-

Historisation

Les entreprises fermées ou radiées ne doivent jamais être supprimées.

Le système doit conserver :

- leur état historique ;
 - leurs documents ;
 - leur situation au moment de l'arrêt.
-

4. Analytics et exploitation métier

Le projet doit produire des traitements analytiques permettant d'exploiter les données collectées.

Le système doit notamment permettre de générer :

- des listes d'entreprises par code postal ;
- des regroupements par activité ;
- des classements financiers ;
- des statistiques d'évolution ;
- des indicateurs sur les entreprises ouvertes/fermées ;
- des analyses temporelles.

Ces traitements doivent être exécutés automatiquement et périodiquement.

5. Supervision et monitoring

Le projet doit inclure un dashboard de supervision temps réel.

Ce dashboard doit permettre de suivre :

- les entreprises actuellement en cours de scraping ;
 - l'étape actuelle du pipeline ;
 - les entreprises entièrement traitées ;
 - les entreprises en attente ;
 - les entreprises découvertes dynamiquement ;
 - les erreurs de scraping ;
 - les erreurs de parsing ;
 - les erreurs de validation ;
 - les échecs liés aux proxys/IP ;
 - les performances globales du système.
-

Listes des proxies :

<https://proxyscrape.com/free-proxy-list>

<https://spys.one/en/>

<https://free-proxy-list.net/en/socks-proxy.html>